

Đánh giá độ phù hợp với từng vị trí của các cầu thủ NBA

Đoàn Nhật Hưng^{1,2,3}, Bùi Ngọc Hoàn^{1,2,3}, Nguyễn Gia Tuấn Anh^{1,2,4}, Trần Quốc Khánh^{1,2,4}

¹ Khoa Khoa học và Kỹ thuật thông tin

² Trường Đại học Công Nghệ Thông Tin

³{23520556, 23520510} @gm.uit.edu.vn

⁴{anhngt, khanhtq} @uit.edu.vn

Tóm tắt

Báo cáo này trình bày một phương pháp tiếp cận nhằm đánh giá và phân loại mức độ phù hợp của các cầu thủ NBA với từng vị trí thi đấu, dựa trên dữ liệu thống kê trong mùa giải chính. Nhóm đã thu thập dữ liệu từ Regular Season của NBA trong 5 mùa giải liên tiếp (2020–2021 đến 2024–2025), sau đó áp dụng các thuật toán học máy để xây dựng mô hình tối ưu, phục vụ cho việc xác suất hoá vị trí thông qua hàm PositionProbability.

1. Giới thiệu

Trong bối cảnh thể thao hiện đại, bóng rổ đã và đang trở thành một trong những môn thể thao phổ biến và hấp dẫn nhất trên toàn cầu. Đặc biệt, NBA (National Basketball Association), giải bóng rổ chuyên nghiệp hàng đầu thế giới luôn thu hút hàng triệu người theo dõi mỗi mùa giải nhờ vào chất lượng chuyên môn cao và sự góp mặt của các ngôi sao hàng đầu.

Cùng với sự phát triển mạnh mẽ của công nghệ và phân tích dữ liệu, các chỉ số thống kê trong NBA ngày càng trở nên phong phú và chi tiết. Điều này mở ra nhiều cơ hội để đánh giá hiệu suất thi đấu, cũng như tiềm năng phát triển của các cầu thủ một cách toàn diện hơn. Tuy nhiên, trong thực tế, việc phân loại và đánh giá cầu thủ không thể chỉ dựa vào một vài con số đơn lẻ, mà cần đến các mô hình phân tích hiện đại có khả năng xử lý và tổng hợp dữ liệu phức tạp.

Trong suốt hơn 74 năm hình thành và phát triển, NBA đã chứng kiến nhiều bước ngoặt lớn về luật thi đấu và chiến thuật, từ sự ra đời của đồng hồ 24 giây (năm 1954), đường ba điểm (1979-1980), cho đến xu hướng "small-ball" những năm gần đây, chiến thuật sử dụng đội hình nhỏ, linh hoạt và thiên về ném xa. Dù thay đổi theo thời đại, các đội bóng vẫn luôn cần bố trí đội hình gồm 5 cầu thủ với các vị trí và vai trò rõ ràng như PG, SG, SF, PF, và C để đạt được hiệu quả thi đấu tối ưu.

Xuất phát từ thực tế đó, nhóm đã lựa chọn đề tài thu thập và phân tích dữ liệu thống kê thi đấu của các cầu thủ NBA trong 5 mùa giải gần nhất (2020–2025), nhằm xây dựng một mô hình phân loại vị trí thi đấu có tính chính xác cao. Nghiên cứu hướng đến

việc đánh giá khả năng phù hợp của cầu thủ với từng vị trí, từ đó phát triển một hàm **PositionProbability**, có khả năng dự đoán và gợi ý vị trí thi đấu dựa trên dữ liệu thực tế.

2. Các công trình nghiên cứu liên quan

Phân loại vị trí cầu thủ trong bóng rổ là một lĩnh vực nghiên cứu thu hút sự quan tâm từ nhiều chuyên gia thể thao và nhà khoa học dữ liệu, với các hướng tiếp cận đa dạng nhằm nâng cao độ chính xác và khả năng ứng dụng thực tiễn.

Bài báo “**Evolution of A Player: Transitions in NBA Player Classifications**” (1) đã sử dụng phân tích thành phần chính (PCA) và phân cụm phân cấp để phân loại cầu thủ NBA từ mùa giải 2000–01. Thông qua ma trận chuyển tiếp Markov, nghiên cứu xác định được 12 nhóm phong cách chơi và quan sát quá trình dịch chuyển vai trò thi đấu theo thời gian. Kết quả cho thấy các cầu thủ trẻ thường có xu hướng chuyển đổi phong cách nhiều hơn, trong khi các ngôi sao có sự ổn định cao hơn trong lối chơi.

Ngoài ra, nghiên cứu “**NBA Player Standalone Game Performance Statistics, Player Position Classification Modeling**” (2) thu thập dữ liệu thi đấu từ mùa giải 2017–2023 và xây dựng mô hình phân loại vị trí cầu thủ dựa trên phản hồi dạng nhị phân (0/1) ứng với từng vị trí. Trong các mô hình thử nghiệm, hồi quy Logistic cho hiệu quả phân loại cao nhất, thể hiện rõ sự phù hợp của các phương pháp học máy truyền thống với các bài toán thể thao.

Cuối cùng, bài báo “**A Cluster Analysis of Basketball Players for Each of the Five Traditionally Defined Positions**” (3) áp dụng phân cụm phân cấp để nhóm cầu thủ theo phong cách chơi, dựa trên 17 chỉ số thống kê từ 15 mùa giải NBA. Nghiên cứu xác định được 4 cụm cho PG-SG-SF, 5 cụm cho PF và 6 cụm cho C, đồng thời phân tích hiệu suất cá nhân thông qua chỉ số Adjusted Plus-Minus (APM). Kết quả cung cấp thông tin quan trọng về sự tương thích chiến thuật trong đội hình.

Tuy các nghiên cứu trên đã đóng góp đáng kể trong việc hiểu và phân loại cầu thủ NBA, phần lớn đều sử dụng dữ liệu quá khứ hoặc chưa cập nhật những xu hướng chiến thuật hiện đại như “small-ball” hay “hybrid roles”. Do đó, nhóm đã thu thập dữ liệu từ 5 mùa giải gần nhất (2020-2025) và phát triển mô hình học máy kết hợp hàm Position Probability nhằm phản ánh chính xác hơn mức độ phù hợp của cầu thủ với từng vị trí thi đấu trong bối cảnh bóng rổ hiện đại.

3. Bộ dữ liệu

3.1. Thu thập dữ liệu

Bộ dữ liệu được thu thập từ 2 nguồn thống kê uy tín trong lĩnh vực bóng rổ bao gồm: <https://www.basketball-reference.com/> và <https://www.nba.com/stats>

Nhóm sử dụng ngôn ngữ lập trình Python, kết hợp với các kỹ thuật HTML parsing và gọi API để tự động hóa quá trình thu thập dữ liệu. Dữ liệu được khai thác từ các mùa giải NBA Regular Season từ 2020–2021 đến 2024–2025, với trọng tâm là các thông số liên quan đến hiệu suất thi đấu của cầu thủ.

3.2. Tổng quan bộ dữ liệu

Sau quá trình thu thập và hợp nhất dữ liệu từ 5 mùa giải riêng biệt, toàn bộ dữ liệu được lưu trữ dưới dạng một **DataFrame tổng hợp**, đóng vai trò là **Bronze Layer** trong quy trình xử lý. Tổng quan về bộ dữ liệu được thể hiện trong bảng dưới đây.

Tên bộ dữ liệu	NBA Player Stats Regular Season 2020–2025
Mô tả	Bộ dữ liệu chứa các chỉ số thống kê chi tiết của cầu thủ NBA trong mùa giải chính (Regular Season), bao gồm điểm số, kiến tạo, rebounds, hiệu suất ném, thời gian kiểm soát bóng, và các chỉ số nâng cao khác.
Mục đích	Phân tích hiệu suất thi đấu và vai trò của cầu thủ qua từng mùa giải. Phân loại vị trí cầu thủ dựa trên dữ liệu thực tế. Hỗ trợ xây dựng mô hình dự đoán Position Player .
Nguồn dữ liệu	Basketball-Reference, nba_stats_tracking, API Python

Phạm vi thời gian	2020–2021 đến 2024–2025
Số bản ghi	2,825
Số thuộc tính (chi tiết ở bảng 6)	object: 3 float64: 70 total: 73

Bảng 1. Chi tiết thuộc tính bộ dữ liệu

Sau khi hoàn tất quá trình thu thập và hợp nhất dữ liệu từ năm mùa giải NBA liên tiếp (2020–2025), nhóm tiến hành các bước tiền xử lý nhằm đảm bảo tính toàn vẹn và độ tin cậy của tập dữ liệu trước khi đưa vào huấn luyện mô hình. Quy trình tiền xử lý bao gồm các bước sau:

Chuẩn hóa chuỗi ký tự (text normalization): Một số tên cầu thủ bị lỗi hiển thị do mã hóa không đúng định dạng Unicode. Ví dụ, Luka Dončić (20-21) được chuẩn hóa thành Luka Dončić (20-21) bằng cách áp dụng hàm chuyển đổi mã ký tự đặc biệt.

Loại bỏ các thuộc tính dư thừa do trùng lặp khi thu thập: Các cột như: Unnamed: 0, two_pt_fg_pct, three_pt_fg_pct, được loại bỏ do phát sinh từ quá trình thu thập dữ liệu từ nhiều nguồn, dẫn đến trùng lặp hoặc có thể được tính toán lại từ các thuộc tính khác. Việc loại bỏ các cột này giúp giảm nhiễu và đơn giản hóa không gian đặc trưng.


Chuyển đổi thống kê tổng về trung bình trận đấu: Nhằm tạo điều kiện so sánh công bằng giữa các cầu thủ có số trận thi đấu không đồng đều, nhóm tiến hành chuẩn hóa một số chỉ số tổng về dạng trung bình theo từng trận:

$$\begin{aligned} \text{MPG} &= \text{MP} / G \\ \text{DRIVES/GM} &= \text{DRIVES} / G \\ \text{DIST_MILES/G} &= \text{DIST_MILES} / G \end{aligned}$$


Xử lý giá trị khuyết (missing values): Một số biến như CATCH_SHOOT_FGM,... xuất hiện giá trị khuyết ngay từ giai đoạn đầu thu thập. Để tránh loại bỏ dữ liệu quan trọng, nhóm lựa chọn điền giá trị mặc định là 0, với giả định rằng cầu thủ không thực hiện hành động tương ứng hoặc dữ liệu không được ghi nhận. Sau khi chuyển đổi các thống kê tổng về dạng trung bình mỗi trận (xem chi tiết bên dưới), các giá trị NaN mới phát sinh đã được xử lý theo cùng phương pháp điền giá trị 0.

Lọc dữ liệu theo ngưỡng thống kê: Để tăng chất lượng phân tích, chỉ giữ lại các cầu thủ đáp ứng hai điều kiện: (1) số trận thi đấu lớn hơn 10 và (2) thời gian trung bình thi đấu lớn hơn 5 phút mỗi trận. Điều này giúp loại bỏ các cầu thủ chỉ góp mặt ngắn hạn và không đủ dữ liệu để phân tích có ý nghĩa.

Kiểm tra phân bố nhân: Nhóm đã thực hiện phân tích phân bố nhân (vị trí thi đấu) trước và sau bước lọc dữ liệu. Kết quả cho thấy tuy có sự chênh lệch giữa các nhóm vị trí, nhưng mức độ mất cân bằng nằm trong ngưỡng chấp nhận được và không gây ảnh hưởng lớn đến mô hình phân loại. Do đó, các kỹ thuật cân bằng nhân như oversampling hoặc undersampling không được áp dụng trong nghiên cứu này.



Hình 1. Phân bố nhân trước khi lọc



Hình 2. Phân bố nhân sau khi lọc


Dữ liệu sau khi tiền xử lý được lưu vào một DataFrame hoàn chỉnh với tên `df_valid_players`, đóng vai trò làm tập dữ liệu đầu vào cho các bước khám phá dữ liệu (EDA) và huấn luyện mô hình ở các phần tiếp theo. Tập dữ liệu này cũng chính là phiên bản Silver Layer trong quy trình xử lý, đạt các điều kiện chất lượng cần thiết, bao gồm: không còn missing values, không còn lỗi tên, dữ liệu đầy đủ cho các bước phân tích tiếp theo.

3.4. EDA - Khám phá dữ liệu


Sau khi hoàn tất tiền xử lý dữ liệu cơ bản, nhóm đã tiến hành phân tích khám phá dữ liệu (EDA) nhằm hiểu rõ hơn về đặc điểm phân phối các biến đầu vào, mối liên hệ giữa các đặc trưng, cũng như xu hướng khác biệt giữa các vị trí thi đấu.

Đầu tiên nhóm quyết định phân tích phân phối của các biến đầu vào. Nhiều biến định lượng trong bộ dữ liệu có phân phối gần chuẩn hoặc đồng đều, phản ánh mức độ ổn định trong hiệu suất thi đấu của phần lớn cầu thủ. Xu hướng này cho thấy đa số các cầu thủ NBA có mức đóng góp trung bình, thường đảm nhiệm vai trò hỗ trợ trong đội hình. (Hình 2)

Ngược lại ở một số biến như: 3PA, DRIVES và TIME_OF_POSSESSION có phân phối lệch phải rõ rệt. Các chỉ số này thường tập trung ở một nhóm nhỏ các cầu thủ có tần suất sử dụng bóng cao, điều này phù hợp với thực tế thi đấu khi chỉ một số ít cầu thủ chủ chốt đảm nhiệm phần lớn nhiệm vụ tấn công trong trận đấu. (Hình 3)




Hình 3. Phân phối của các biến



Hình 4. Phân phối của các biến (t.t)

Trong phần tiếp theo, nhóm tập trung phân tích các chỉ số được đánh giá là đại diện cho phong cách thi đấu đặc trưng của từng vị trí,

nhằm làm rõ sự khác biệt thống kê giữa các vai trò trên sân.




Hình 5. Phân phối số lần ném 3 điểm (3PA) và tỷ lệ thành công (3P%)

Có thể thấy rằng, sự gia tăng số lần ném 3 điểm trên mỗi 100 possessions ở tất cả các vị trí cho thấy ném 3 đang trở thành kỹ năng bắt buộc trong bóng rổ hiện đại, bất kể vị trí thi đấu. Xu hướng "small-ball" góp phần thúc đẩy điều này khi các cầu thủ vòng ngoài có hiệu suất ném 3 tốt hơn và được ưu tiên nhiều hơn trong lối chơi.


Biểu đồ đường cho thấy số lần ném 3 điểm có thể dùng để phân biệt khá rõ các vị trí như C so với SG và PG. Hiệu suất ném 3 điểm có xu hướng giảm có thể giải thích đơn giản là bởi vì số lượng cú ném nhiều hơn đã dẫn tới giảm đi độ chính xác trong những cú ném này.

Ngược lại, số lần và hiệu suất ném 2 điểm lại có xu hướng đối lập. Center là vị trí nổi bật nhất khi có số lần và hiệu suất ném 2 điểm cao nhất, cho thấy vai trò chủ yếu của họ ở khu vực gần rổ. Dù không có biểu đồ vị trí ném cụ thể, nhưng dữ liệu cũng phản ánh rõ chiến lược tối ưu hoá "giá trị kỳ vọng" (expected value): hoặc ném gần rổ (hiệu suất cao), hoặc ném 3 điểm (giá trị cao). Việc giảm sút các cú ném 2 điểm tầm trung nhưng tăng hiệu quả các cú ném gần rổ cũng lý giải cho việc hiệu suất ném 2 điểm đang có xu hướng tăng lên



Hình 6. Phân phối số lần ném 2 điểm (2PA) và tỷ lệ thành công (2P%)


Tiếp theo, nhóm quyết định khảo sát thêm một số chỉ số khác như thời gian kiểm soát bóng, nhằm làm rõ vai trò điều phối và ảnh hưởng chiến thuật đặc trưng của từng vị trí thi đấu.




Hình 7. Thời gian kiểm soát bóng/100 tình huống

Từ hình 7, có thể nhận thấy dễ dàng rằng trong xuyên suốt 5 mùa giải PG luôn có thời gian giữ bóng nhiều nhất, thể hiện rõ vai trò điều phối lối chơi của vị trí này. Ngược lại C có xu hướng hỗ trợ đồng đội nhiều hơn dẫn đến thời gian cầm bóng rất ít. Đây tiếp tục là một đặc trưng quan trọng giúp phân biệt được 2 vị trí này.

Để tìm ra các đặc trưng giúp phân biệt được 3 vị trí còn lại, nhóm quyết định thực hiện theo những bước khai phá dữ liệu đối với các chỉ số khác. Hai chỉ số được lựa chọn đó là quãng đường di chuyển mỗi trận (DIST_MILES/G) và Số lần chạm bóng khi tấn công (FRONT_CT_TCM/GM).



Hình 8. Số lần chạm bóng trung bình mỗi trận



Hình 9. Quãng đường di chuyển trung bình mỗi trận

Có thể kết luận được rằng: Các vị trí SG (Shooting Guard), SF (Small Forward) và PF (Power Forward) ngày càng có sự giao thoa về vai trò và phạm vi hoạt động trên sân. Dựa vào

các chỉ số như 3PA, 3P% và 2PA, có thể thấy cả ba vị trí này đều tham gia tích cực vào cả các tình huống dứt điểm gần rổ lẫn các pha ném xa từ vòng ngoài.

Đáng chú ý, PF, vốn được xem là một vị trí “big man” truyền thống, thường hoạt động chủ yếu trong khu vực dưới rổ, hiện nay cũng có xu hướng di chuyển rộng hơn và thực hiện nhiều cú ném 3 điểm hơn, tương đồng với vai trò thường thấy ở SG và SF.

Những thay đổi này phản ánh rõ xu hướng chiến thuật hiện đại trong NBA, nơi mà ranh giới giữa các vị trí đang dần bị xóa mờ, và khái niệm “vị trí lai” (hybrid positions) ngày càng trở nên phổ biến.

3.5. Tiềm xử lý dữ liệu nâng cao

Những cột mang thông tin tổng hợp toàn mùa (ví dụ: tổng số phút thi đấu, tổng điểm) hoặc có thể suy diễn trực tiếp từ các đặc trưng khác đã bị loại bỏ. Việc này nhằm giảm nhiễu thông tin, tránh rò rỉ dữ liệu (data leakage) và giảm số chiều của không gian đặc trưng mà không làm mất đi giá trị thông tin. Sau khi loại bỏ bộ dữ liệu từ 89 đặc trưng đã được rút xuống còn 51 đặc trưng.

Tiếp theo như đã đề cập ở phần trước, ở NBA có một nhóm cầu thủ được gọi là “Superstar” với những chỉ số vượt trội so với những cầu thủ khác, đây được xem là các outlier trong bộ dữ liệu của nhóm. Với các giá trị outlier này, nhóm quyết định sẽ không loại bỏ vì điều này là không hợp lý trong thực tế. Vì vậy nhóm quyết định log-transform có chọn lọc những giá trị có $|\text{skewness}| > 1$ để làm giảm ảnh hưởng của các giá trị ngoại lai này.

Công thức log-transform được biểu diễn như sau:

$$x' = \log(x + 1)$$

Trong đó x' : giá trị sau khi biến đổi

x : giá trị trước khi biến đổi

Chuẩn hóa đặc trưng

Toàn bộ các đặc trưng định lượng được chuẩn hóa theo phương pháp **z-score**, với công thức:

$$x_i^{(\text{scaled})} = \frac{x_i - \mu}{\sigma}$$

x_i là giá trị ban đầu của đặc trưng.

μ là giá trị trung bình (mean) của đặc trưng x .

σ là độ lệch chuẩn (standard deviation) của đặc trưng.

Sau khi hoàn tất bước phân tích dữ liệu, nhóm đã tiến hành đánh giá chất lượng tổng thể của tập dữ

liệu. Cụ thể, bộ dữ liệu đã thỏa mãn năm tiêu chí quan trọng trong khai phá dữ liệu: tính đầy đủ, tính cập nhật, tính đa dạng, tính chính xác, và tính tin cậy.

Ngoài ra, nhóm quyết định giữ lại toàn bộ các đặc trưng định lượng được lựa chọn sau bước tiền xử lý nâng cao, do mỗi đặc trưng đều thể hiện được tiềm năng phân tách theo vị trí và mang giá trị thông tin phù hợp để phục vụ huấn luyện mô hình. Các đặc trưng này bao phủ đa dạng các khía cạnh như khả năng kiểm soát bóng, ghi điểm, di chuyển và đóng góp chiến thuật, phản ánh đúng vai trò thực tiễn của từng vị trí trong NBA hiện đại. Đây cũng chính là lớp Gold Layer của nhóm, sẵn sàng cho việc huấn luyện mô hình.

4. Mô hình máy học

4.1. Mô hình

4.1.1. LogisticRegression

Logistic Regression là một trong những mô hình phân loại cơ bản và phổ biến nhất trong học máy. Mô hình này xây dựng một hàm tuyến tính để dự đoán xác suất một mẫu thuộc về một trong các lớp (ở đây là các vị trí PG, SG, SF, PF, C), thông qua hàm sigmoid hoặc softmax cho bài toán phân loại đa lớp.

Hàm dự đoán có dạng:

$$P(y = k|x) = \frac{e^{w_k^T x}}{\sum_{j=1}^K e^{w_j^T x}}$$

- x : vector đặc trưng của cầu thủ
- w_k : vector trọng số của lớp k

Mô hình Logistic Regression được lựa chọn nhằm đóng vai trò baseline tuyến tính, giúp kiểm tra xem các đặc trưng đã tiền xử lý có đủ khả năng tách lớp theo không gian tuyến tính hay không. Mặc dù đơn giản, mô hình này vẫn cho kết quả đáng tin cậy nếu dữ liệu đã được chuẩn hóa tốt.

4.1.2. Support Vector Machine (SVM)

SVM là một mô hình phân loại mạnh, đặc biệt hiệu quả trong trường hợp dữ liệu có số chiều cao (nhiều đặc trưng) và số lượng mẫu vừa phải như trong nghiên cứu này. Mô hình tìm ra siêu phẳng (hyperplane) phân tách tối ưu giữa các lớp, với biên phân chia (margin) lớn nhất.

Với kernel phi tuyến (ví dụ: RBF), SVM có

thể ánh xạ dữ liệu vào không gian đặc trưng cao hơn để xử lý các quan hệ phi tuyến giữa đặc trưng và vị trí cầu thủ.

Mô hình SVM được lựa chọn để kiểm tra khả năng phân biệt giữa các lớp có đặc trưng chồng lấn, điển hình như các vị trí SG-SF-PF trong bóng rổ hiện đại, vốn ngày càng xuất hiện “hybrid players”.

4.1.3. RandomForest

Random Forest là một thuật toán ensemble learning sử dụng tập hợp nhiều cây quyết định (decision trees), mỗi cây được huấn luyện trên một tập con của dữ liệu (bagging) và chọn ngẫu nhiên các đặc trưng tại mỗi lần chia nhánh. Dự đoán cuối cùng là tổng hợp từ các cây thông qua bỏ phiếu đa số (classification).

Thuật toán này đặc biệt phù hợp với bài toán có quan hệ phi tuyến phức tạp, và cung cấp độ quan trọng của từng đặc trưng (feature importance), một lợi thế trong việc phân tích vai trò của các chỉ số thống kê trong việc quyết định vị trí thi đấu.

Random Forest thường đạt hiệu suất cao trong các tập dữ liệu thực tế có nhiễu và tương tác đặc trưng mạnh, phù hợp với tính chất của dữ liệu NBA.

4.2. Độ đo đánh giá

4.2.1. Accuracy

Accuracy đo tỷ lệ mẫu được dự đoán đúng so với tổng số mẫu, công thức tính như sau:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

TP: True Positives – số mẫu dương được dự đoán đúng

TN: True Negatives – số mẫu âm được dự đoán đúng

FP: False Positives – số mẫu âm bị dự đoán nhầm thành dương

FN: False Negatives – số mẫu dương bị dự đoán nhầm thành âm

4.2.2. Precision, Recall và F1-score

Với bài toán đa lớp, các độ đo này được tính trên từng lớp riêng biệt và sau đó lấy trung bình (macro average) để phản ánh toàn cục:

Precision: Đo lường tính chính xác của mô hình khi dự đoán một lớp cụ thể.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall: Đo khả năng phát hiện đúng các mẫu thực sự thuộc lớp đó.

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1-score: Trung bình điều hòa giữa Precision và Recall.

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Các độ đo này phù hợp để đánh giá sự cân bằng giữa đúng và đủ, đặc biệt hữu ích trong trường hợp có sự chồng lấn vai trò giữa các vị trí như SG, SF và PF.

4.3. Huấn luyện mô hình và kết quả

Sau khi hoàn thành các bước tiền xử lý, phân tích và đánh giá dữ liệu, nhóm tiến hành huấn luyện và kiểm thử mô hình bằng ba thuật toán học máy đã nêu ở trên. Bộ dữ liệu sẽ được chia train:test theo tỉ lệ 75:25. Quá trình đánh giá được thực hiện thông qua kỹ thuật Cross-Validation kết hợp với phương pháp tìm kiếm siêu tham số tối ưu bằng GridSearchCV nhằm đảm bảo độ chính xác và khả năng tổng quát hóa của mô hình.

Kết quả mà nhóm thu được sau khi kiểm nghiệm mô hình như sau:

	LogReg	SVM	RF
Accuracy (Mean)	0.6648	0.6540	0.6433

Bảng 2. Kết quả trên độ đo Accuracy

	LogReg	SVM	RF
C	0.84	0.83	0.80
PF	0.56	0.54	0.53
PG	0.81	0.80	0.74
SF	0.47	0.47	0.48
SG	0.62	0.64	0.60

Bảng 3. Kết quả trên độ đo Precision

	LogReg	SVM	RF
C	0.85	0.85	0.84
PF	0.55	0.54	0.53
PG	0.83	0.83	0.81
SF	0.44	0.41	0.38
SG	0.63	0.65	0.62


Bảng 4. Kết quả trên độ đo Recall

	LogReg	SVM	RF
C	0.84	0.84	0.82
PF	0.55	0.54	0.52
PG	0.82	0.82	0.78
SF	0.45	0.43	0.42
SG	0.63	0.64	0.60

Bảng 5. Kết quả trên độ đo F1-score

Qua kết quả thực nghiệm trên 4 độ đo mặc dù cho accuracy có phần tương đương, nhưng chênh lệch giữa tập train và test của LogReg chênh lệch nhiều hơn 2 mô hình còn lại. Ngoài ra với 3 chỉ số còn lại mô hình SVM cho thấy độ ổn định đặc biệt là với các lớp có xu hướng lai- hybrid players, vì vậy nhóm quyết định sử dụng mô hình SVM cho việc phân tích kết quả và xây dựng hàm PositionPossibility.

4.4. Phân tích kết quả



Hình 10. Confusion Matrix của mô hình SVM

Mô hình phân loại rất tốt các vị trí C và PG với độ chính xác cao và ít bị nhầm lẫn.


Các vị trí PF, SF, SG có hiện tượng nhầm lẫn chéo lẫn nhau - đặc biệt là giữa PF ↔ SF và SF ↔ SG.

Phản ánh thực tế bóng rổ hiện đại: các vị trí như SF, PF, SG có vai trò linh hoạt và thường giao thoa về nhiệm vụ thi đấu, gây khó khăn cho mô hình trong việc phân biệt rõ ràng.


4.5. Xây dựng hàm PositionPossibility

Hàm PositionPossibility được thiết kế để trực quan hóa xác suất mà mô hình dự đoán một cầu thủ NBA sẽ chơi ở từng vị trí trong một mùa giải cụ thể. Dựa trên tên cầu thủ và năm thi đấu (được kết hợp thành player_ID), hàm này xác định vị trí tương ứng trong tập dữ liệu đã được dự đoán (tập train hoặc test), sau đó truy xuất giá trị xác suất dự đoán cho từng vị trí từ mô hình SVM đã huấn luyện. Kết quả được hiển thị dưới dạng biểu đồ tròn (pie chart), cho

thấy phân bố phần trăm khả năng cầu thủ đó được phân loại vào 5 vị trí: C, PF, PG, SF và SG. Việc sử dụng biểu đồ giúp người dùng dễ dàng giải thích tính không chắc chắn và mức độ phân biệt giữa các nhãn mà mô hình học máy đưa ra.



Hình 11. Xác suất phân bố vị trí của Stephen Curry(20-21)



Hình 12. Xác suất phân bố vị trí Stephen Curry (24-25)

Từ biểu đồ phân bố vị trí xác suất của Stephen Curry từ năm đầu tiên của khảo sát so với năm cuối cùng của khảo sát có thể khẳng định được rõ ràng rằng đã có sự chuyển dịch trong phong cách thi đấu của những cầu thủ NBA, vì vậy ranh giới giữa các vị trí hiện nay ngày càng mờ nhạt và khó để phân biệt.

5. Kết luận và hướng phát triển

5.1. Phân tích lỗi và hạn chế

Mặc dù mô hình đạt được hiệu suất phân loại tương đối hợp lý, vẫn tồn tại những hạn chế đáng chú ý. Cụ thể, mô hình gặp khó khăn trong việc phân biệt giữa các vị trí có đặc điểm thi đấu tương đồng, điển hình là giữa small forward (SF) và power forward (PF), cũng như giữa SF và shooting guard (SG). Nguyên nhân chủ yếu đến từ sự giao thoa vai trò trong bóng rổ hiện đại, nơi nhiều cầu thủ đảm nhận những nhiệm vụ linh hoạt vượt ra khỏi phạm vi định nghĩa vị trí truyền

thống. Ngoài ra, phân tích ma trận nhầm lẫn cho thấy tỷ lệ False Negatives (Type II Error) chiếm ưu thế so với False Positives, cho thấy mô hình có xu hướng bỏ sót các trường hợp thuộc nhãn thực tế thay vì dự đoán sai nhãn khác.

5.2. Tổng kết

Mặc dù độ chính xác tổng thể của các mô hình phân loại chưa đạt mức tối ưu, đặc biệt ở những vị trí có vai trò linh hoạt như SF–PF hoặc SF–SG, nghiên cứu này vẫn cho thấy tiềm năng trong việc khám phá các xu hướng chuyển dịch vị trí thi đấu trong bóng rổ hiện đại. Mô hình đã phản ánh một thực tế quan sát được trong NBA ngày nay: sự mờ nhạt dần của các ranh giới vị trí truyền thống, cùng với sự nổi lên của các cầu thủ đa năng đảm nhiệm nhiều vai trò trên sân.

Thông qua biểu đồ xác suất và phân tích lỗi, nhóm ghi nhận rằng các mô hình học máy không chỉ hỗ trợ gán nhãn vị trí cầu thủ, mà còn giúp làm nổi bật các mẫu hình sai lệch, từ đó cung cấp hiểu biết sâu sắc hơn về cấu trúc đội hình và cách cầu thủ được sử dụng. Do đó, dù hiệu suất phân loại chưa hoàn hảo, hệ thống đã bước đầu cho thấy hiệu quả như một công cụ phân tích chiến thuật và nhận diện xu hướng thay đổi chiến lược thi đấu.

Trong tương lai, việc kết hợp thêm dữ liệu thời gian, vai trò thực tế trong trận đấu, hoặc thông tin đội bóng có thể giúp cải thiện độ chính xác và tăng cường khả năng diễn giải của mô hình.

5.3. Hướng phát triển

Nghiên cứu trong tương lai có thể tập trung vào một số khía cạnh nhằm cải thiện hiệu quả mô hình và tăng cường khả năng diễn giải:

- Thiết kế đặc trưng phân biệt cao hơn: Việc phát triển thêm các đặc trưng chuyên sâu có khả năng phân biệt rõ giữa các nhóm vị trí có mức độ giao thoa cao, điển hình như SG–SF và SF–PF, là cần thiết. Các đặc trưng này có thể bao gồm tỷ lệ đóng góp trong tấn công/phòng thủ, phân bố vùng hoạt động trên sân, hoặc chỉ số liên quan đến chiến thuật. Một số nghiên cứu đề xuất sử dụng dữ liệu quỹ đạo di chuyển và phân tích các tương tác vị trí theo thời gian để trích xuất đặc trưng chiến thuật có tính phân biệt cao (4).
- Thay vì gán nhãn vị trí cứng nhắc theo truyền thống, việc phân loại cầu thủ theo phong cách chơi (playstyle) có thể phản ánh chân thực hơn vai trò thực tế trên sân, phù hợp với xu thế chiến thuật linh hoạt của bóng rổ hiện đại. Đây cũng là hướng tiếp cận được nhiều nghiên cứu tiên tiến

áp dụng học sâu và dữ liệu không gian, thời gian để mô phỏng hành vi và vai trò cầu thủ trong thực chiến (5)

- Mở rộng phạm vi dữ liệu: Triển khai mô hình trên các giải đấu khác như NCAA, EuroLeague, hoặc WNBA sẽ giúp kiểm chứng tính tổng quát của mô hình và phân tích sự khác biệt cấu trúc vị trí giữa các môi trường thi đấu.
- Khảo sát và so sánh với các thuật toán tiên tiến: Việc áp dụng các mô hình học máy mạnh hơn như XGBoost, CatBoost, hoặc các kiến trúc học sâu có thể nâng cao hiệu năng phân loại, đặc biệt trong việc nắm bắt các quan hệ phi tuyến giữa đặc trưng và nhãn đầu ra.

Những hướng mở rộng này không chỉ nhằm nâng cao độ chính xác mô hình, mà còn góp phần thúc đẩy các nghiên cứu phân tích chiến thuật trong thể thao theo hướng định lượng và có thể diễn giải.

Tài liệu tham khảo

- (1) Richardson, C. A. (2019). [Evolution of a player: Transitions in NBA player classifications. SSRN Electronic Journal.](#)
- (2) Salce, A. (2023). [NBA player standalone game performance statistics, player position classification modeling.](#) University of Arizona.
- (3) Duman, A., Sennaroğlu, B., & Tuzkaya, G. (2022). [A cluster analysis of basketball players for each of the five traditionally defined positions. Proceedings of the Institution of Mechanical Engineers, Part P: Journal of Sports Engineering and Technology, 238\(1\), 55-75.](#)
- (4) Harmon, M., Ebrahimi, A., Lucey, P., & Klabjan, D. (2016). [Predicting shot making in basketball learnt from adversarial multiagent trajectories](#)
- (5) Cervone, D., D'Amour, A., Bornn, L., & Goldsberry, K. (2016). [A multiresolution stochastic process model for predicting basketball possession outcomes. Journal of the American Statistical Association](#)

Chú thích

No	Attribute	Data Type	Attribution Group	Description
0	PLAYER_NAME	object	Player Information	Tên cầu thủ
1	Age	float64	Player Information	Độ tuổi của cầu thủ
2	Team	object	Player Information	Đội bóng mà cầu thủ đang thi đấu
3	Pos	object	Player Information	Vị trí thi đấu (PG, SG, SF, PF, C)
4	G	float64	Game Statistics	Số trận đã chơi
5	GS	float64	Game Statistics	Số trận xuất phát (bắt đầu)
6	MP	float64	Game Statistics	Thời gian thi đấu trung bình (phút)
7	FG	float64	Scoring	Số lần ghi điểm từ sân
8	FGA	float64	Scoring	Số lần ném bóng từ sân (tổng số cú ném)
9	FG%	float64	Scoring	Tỷ lệ ghi điểm từ sân (FG/FGA)
10	3P	float64	Scoring	Số lần ghi ba điểm
11	3PA	float64	Scoring	Số lần ném bóng ba điểm
12	3P%	float64	Scoring	Tỷ lệ ghi ba điểm (3P/3PA)
13	2P	float64	Scoring	Số lần ghi hai điểm
14	2PA	float64	Scoring	Số lần ném bóng hai điểm
15	2P%	float64	Scoring	Tỷ lệ ghi hai điểm (2P/2PA)
16	eFG%	float64	Scoring	Tỷ lệ ghi điểm hiệu quả $(FG + 0.5 * 3P) / FGA$
17	FT	float64	Scoring	Số lần ghi điểm từ ném phạt
18	FTA	float64	Scoring	Số lần ném phạt
19	FT%	float64	Scoring	Tỷ lệ ghi điểm từ ném phạt (FT/FTA)
20	ORB	float64	Rebounding	Số lần ghi điểm từ pha rebound (bắt bóng bật) sau tấn công
21	DRB	float64	Rebounding	Số lần ghi điểm từ pha rebound sau phòng ngự
22	TRB	float64	Rebounding	Tổng số rebound (ORB + DRB)
23	AST	float64	Assists	Số lần kiến tạo
24	STL	float64	Defense	Số lần cướp bóng
25	BLK	float64	Defense	Số lần chặn bóng
26	TOV	float64	Turnovers	Số lần mất bóng
27	PF	float64	Fouls	Số lần phạm lỗi
28	PTS	float64	Scoring	Tổng số điểm ghi được
29	ORtg	float64	Team Rating	Tỷ lệ ghi điểm của đội khi cầu thủ trên sân
30	DRtg	float64	Team Rating	Tỷ lệ điểm bị ghi khi cầu thủ trên sân
31	PER	float64	Efficiency	Chỉ số hiệu suất cá nhân
32	TS%	float64	Efficiency	Tỷ lệ ghi điểm hiệu quả $(PTS / (2 * (FGA + 0.44 * FTA)))$
33	3PAr	float64	Shooting	Tỷ lệ ném ba điểm trong tổng số cú ném
34	FTr	float64	Shooting	Tỷ lệ ném phạt (FTA/FGA)
35	ORB%	float64	Rebounding	Tỷ lệ rebound tấn công
36	DRB%	float64	Rebounding	Tỷ lệ rebound phòng ngự
37	TRB%	float64	Rebounding	Tỷ lệ rebound tổng

38	AST%	float64	Assists	Tỷ lệ kiến tạo
39	STL%	float64	Defense	Tỷ lệ cướp bóng
40	BLK%	float64	Defense	Tỷ lệ chặn bóng
41	TOV%	float64	Turnovers	Tỷ lệ mất bóng
42	USG%	float64	Usage	Tỷ lệ sử dụng bóng
43	OWS	float64	Wins Contribution	Số chiến thắng đóng góp của cầu thủ
44	DWS	float64	Wins Contribution	Số chiến thắng đóng góp phòng ngự
45	WS	float64	Wins Contribution	Tổng số chiến thắng đóng góp
46	WS/48	float64	Wins Contribution	Số chiến thắng đóng góp trung bình mỗi 48 phút
47	OBPM	float64	Impact	Chỉ số ảnh hưởng tấn công
48	DBPM	float64	Impact	Chỉ số ảnh hưởng phòng ngự
49	BPM	float64	Impact	Chỉ số ảnh hưởng tổng hợp
50	VORP	float64	Value	Giá trị đóng góp của cầu thủ so với một cầu thủ thay thế
51	pct_of_FGA_twos	float64	Shooting	Tỷ lệ ném hai điểm trong tổng số cú ném
52	pct_of_FGA_threes	float64	Shooting	Tỷ lệ ném ba điểm trong tổng số cú ném
53	two_pt_fg_pct	float64	Scoring	Tỷ lệ ghi điểm từ hai điểm
54	three_pt_fg_pct	float64	Scoring	Tỷ lệ ghi điểm từ ba điểm
55	DRIVES	float64	Driving Statistics	Số lần tấn công
56	DRIVE_FGM	float64	Driving Statistics	Số lần ghi điểm từ tấn công
57	DRIVE_FGA	float64	Driving Statistics	Số lần ném bóng từ tấn công
58	DRIVE_PASSES	float64	Driving Statistics	Số lần kiến tạo từ tấn công
59	CATCH_SHOOT_FGM	float64	Shooting	Số lần ghi điểm từ pha bắt bóng
60	CATCH_SHOOT_FGA	float64	Shooting	Số lần ném bóng từ pha bắt bóng
61	CATCH_SHOOT_FG3M	float64	Shooting	Số lần ghi điểm ba điểm từ pha bắt bóng
62	CATCH_SHOOT_FG3A	float64	Shooting	Số lần ném ba điểm từ pha bắt bóng
63	TOUCHES	float64	Touches	Tổng số lần chạm bóng
64	FRONT_CT_TOUCHES	float64	Touches	Số lần chạm bóng ở khu vực trước
65	TIME_OF_POSS	float64	Possession	Thời gian sở hữu bóng
66	PULL_UP_FGM	float64	Shooting	Số lần ghi điểm từ pha nhảy lên
67	PULL_UP_FGA	float64	Shooting	Số lần ném bóng từ pha nhảy lên
68	PULL_UP_FG3M	float64	Shooting	Số lần ghi điểm ba điểm từ pha nhảy lên
69	PULL_UP_FG3A	float64	Shooting	Số lần ném ba điểm từ pha nhảy lên
70	DIST_MILES	float64	Distance	Tổng số dặm di chuyển
71	DIST_MILES_OFF	float64	Distance	Tổng số dặm di chuyển khi không cầm bóng
72	DIST_MILES_DEF	float64	Distance	Tổng số dặm di chuyển khi phòng ngự

Bảng 6: Metadata các thuộc tính cầu thủ